

Аналитическая записка

Курсовая работа по дисциплине классического машинного обучения.

Тема: прогнозирование свойств химических соединений, потенциально активных против вируса гриппа, на основе молекулярных дескрипторов.

В записке описаны этапы разведочного анализа, постановка задач регрессии и классификации, сравнение моделей и интерпретация полученных метрик.

Оглавление

Оглавление	1
1. Постановка задачи	2
2. Разведочный анализ данных	2
2.1. Графики EDA	3
3. Методология	6
4. Результаты моделирования	7
4.1. Регрессия IC50	7
4.2. Регрессия CC50	8
4.3. Регрессия SI	9
4.4. Классификация: IC50 выше медианы	10
4.5. Классификация: CC50 выше медианы	11
4.6. Классификация: SI выше медианы	12
4.7. Классификация: SI > 8	13
5. Сравнение подходов	14
6. Ограничения и что можно улучшить	15
7. Заключение	15

1. Постановка задачи

Химики передали таблицу из 1000 соединений. Для каждого есть три целевых показателя и большое количество числовых признаков (молекулярных дескрипторов).

IC50 - это, если совсем просто, концентрация вещества, при которой оно как-то влияет на вирус. В задании написано, что меньшее значение обычно считается лучше, потому что эффект достигается при меньшей дозе. Единицы измерения в данных - мМ.

CC50 характеризует цитотоксичность для клеток. Чем выше значение CC50, тем ниже выраженность токсического эффекта при сопоставимых условиях.

SI - индекс селективности. В данных подтверждено соотношение $SI = CC50 / IC50$. Показатель отражает баланс между противовирусной активностью и токсичностью: более высокий SI соответствует более селективному соединению.

Остальные столбцы - молекулярные дескрипторы: числовые характеристики структуры молекулы (масса, полярность, топология, фрагменты ароматических колец и т.д.). Примеры: MolLogP, TPSA, fr_benzene.

В работе нужно было построить:

- три модели регрессии (IC50, CC50, SI);
- четыре модели классификации (превышение медианы для каждого показателя и отдельно $SI > 8$).

2. Разведочный анализ данных

В датасете 1001 наблюдений и 210 признаков плюс три целевые переменные. Данные представлены в виде табличной матрицы признаков и векторов целевых значений.

Общее число пропусков: 36. Они сосредоточены в небольшом числе столбцов (дескрипторы зарядов и BCUT2D). Пропуски заполнены медианой; удаление строк не применялось, так как потери наблюдений были бы минимальны.

Константных признаков: 18 (одинаковое значение для всех объектов). Такие столбцы исключены из обучения. Итоговое число признаков: 192.

Распределения IC50, CC50 и SI скошены вправо (рисунок 1). Для регрессии применено $\log_{1p}$ -преобразование целевых переменных.

Проверка $SI = CC50 / IC50$ показала практически нулевое расхождение с исходным столбцом. При прогнозировании SI входные признаки IC50 и CC50 не использовались, чтобы исключить утечку информации из целевой переменной.

2.1. Графики EDA

На этапе EDA построены графики распределений, Q-Q plots, парных зависимостей и корреляционная heatmap.




Рисунок 1. Распределения IC50, CC50 и SI.

На гистограммах видно, что у всех трёх показателей длинный правый хвост - большинство значений скромные, но есть отдельные очень большие.




Рисунок 2. Q-Q графики для $\log_{1p}(\text{IC}_{50})$, $\log_{1p}(\text{CC}_{50})$ и $\log_{1p}(\text{SI})$.

После $\log_{1p}$ -преобразования точки ложатся ближе к прямой, чем в исходной шкале. Полной идеальной нормальности нет, но для регрессии так обычно проще.




Рисунок 3. Парные зависимости между IC_{50} , CC_{50} и SI .

Между CC50 и SI связь заметнее, чем между IC50 и SI. Это логично, потому что SI считается через CC50 и IC50.




Рисунок 4. Корреляция целевых показателей и ключевых дескрипторов.

Для наглядности построена матрица корреляций для целевых показателей и ряда ключевых дескрипторов (MolWt, MolLogP, TPSA и др.). Полная матрица всех 200+ признаков была бы трудночитаемой.

Для задач классификации использовались такие пороги:

- ic50_above_median: порог 46.5852, доля класса '1' = 50.0%
- cc50_above_median: порог 411.0393, доля класса '1' = 49.9%
- si_above_median: порог 3.8462, доля класса '1' = 50.0%

- si_above_8: порог 8.0000, доля класса '1' = 35.7%

Задачи 'выше медианы' получились примерно сбалансированными (около 50/50). А вот $SI > 8$ - нет: положительных примеров заметно меньше. Это потом сказалось на метриках классификации.

3. Методология

Пайплайн обработки и моделирования:

1. Загрузка Excel, отделение целевых столбцов от признаков.
2. Удаление константных признаков, импутация пропусков медианой.
3. Разбиение 80% train / 20% test, random_state=42 для воспроизводимости.
4. Для регрессии - $\log 1p(y)$. Для классификации - бинарная метка по порогу.
5. Сравнение нескольких моделей sklearn с GridSearchCV (5 фолдов).

Модели для регрессии: Ridge, ElasticNet, RandomForest, GradientBoosting, SVR.

Для классификации: LogisticRegression, RandomForest, GradientBoosting, SVC.

Сравнивались линейные модели, ансамбли на деревьях и методы опорных векторов в соответствии с требованиями задания.

Нейросетевые подходы не применялись (работа по классическому машинному обучению).

Метрики регрессии: RMSE, MAE, R2 (считаются на log-шкале, если было преобразование).

Метрики классификации: accuracy, precision, recall, F1, ROC-AUC.

Код в репозитории разнесён по задачам: EDA отдельно, все скрипты моделей лежат в папке models/. Так проще проверять и воспроизводить эксперименты.

4. Результаты моделирования

4.1. Регрессия IC50

Численные результаты на отложенной выборке:

- лучшая модель: RandomForest
- параметры: {'model__max_depth': 20, 'model__min_samples_leaf': 3, 'model__n_estimators': 200}
- RMSE: 1.4484
- MAE: 1.1374
- R2: 0.4550

Сравнение моделей по CV RMSE (чем меньше, тем лучше):

- RandomForest: 1.4163
- GradientBoosting: 1.4299
- SVR: 1.4529
- ElasticNet: 1.5893
- Ridge: 1.7103

Интерпретация результатов.

Лучшая модель для IC50: RandomForest. R2 на тестовой выборке: 0.45 (около 45% объяснённой дисперсии в log-шкале). Модель улавливает часть закономерностей между дескрипторами и активностью.

Линейные модели (Ridge, ElasticNet) уступили ансамблям, что указывает на нелинейный характер зависимости. RandomForest и GradientBoosting показали сопоставимое качество.

Для дальнейшего улучшения целесообразны расширение выборки и отбор признаков (190+ признаков при 1000 наблюдениях создаёт риск переобучения).

Наиболее значимые признаки по оценке модели: VSA_EState8, VSA_EState4, VSA_EState6. Для алгоритма они используются как числовые дескрипторы без дополнительной химической интерпретации на уровне отдельных столбцов.

4.2. Регрессия CC50

Численные результаты на отложенной выборке:

- лучшая модель: RandomForest
- параметры: {'model__max_depth': 10, 'model__min_samples_leaf': 3, 'model__n_estimators': 100}
- RMSE: 1.1373
- MAE: 0.8193
- R2: 0.4312

Сравнение моделей по CV RMSE (чем меньше, тем лучше):

- RandomForest: 1.2196
- GradientBoosting: 1.2249
- SVR: 1.2702
- ElasticNet: 1.3782
- Ridge: 1.9118

Интерпретация результатов.

Лучшая модель для CC50: RandomForest, $R^2 = 0.431$. Картина аналогична IC50: ансамбли деревьев превосходят линейные модели.

Среди значимых признаков часто встречаются дескрипторы, связанные с размером молекулы и липофильностью (MolLogP и др.).

Прямое сравнение RMSE между задачами IC50 и CC50 затруднено из-за различий в распределениях целевых переменных.

Наиболее значимые признаки по оценке модели: BCUT2D_MWLOW, Каппа1, NHONCount. Для алгоритма они используются как числовые дескрипторы без дополнительной химической интерпретации на уровне отдельных столбцов.

4.3. Регрессия SI

Численные результаты на отложенной выборке:

- лучшая модель: RandomForest
- параметры: {'model__max_depth': 10, 'model__min_samples_leaf': 3, 'model__n_estimators': 100}
- RMSE: 1.2643
- MAE: 0.9285
- R2: 0.3395

Сравнение моделей по CV RMSE (чем меньше, тем лучше):

- RandomForest: 1.1837
- GradientBoosting: 1.1988
- SVR: 1.2462
- ElasticNet: 1.3023
- Ridge: 1.5013

Интерпретация результатов.

Прогнозирование SI показало наименьшее качество: $R^2 = 0.34$ (модель RandomForest). Это ожидаемо, поскольку SI является отношением двух величин с собственной вариативностью.

Признаки IC50 и CC50 намеренно не включались во входные данные, чтобы избежать утечки целевой информации.

Альтернативный подход - прогноз IC50 и CC50 с последующим вычислением SI - может дать иной результат и требует отдельного эксперимента.

Наиболее значимые признаки по оценке модели: VSA_EState6, VSA_EState8, SMR_VSA7. Для алгоритма они используются как числовые дескрипторы без дополнительной химической интерпретации на уровне отдельных столбцов.

4.4. Классификация: IC50 выше медианы

Численные результаты на отложенной выборке:

- порог отсечения: 46.58518345980803
- лучшая модель: RandomForest
- параметры: {'model__max_depth': 10, 'model__min_samples_leaf': 3, 'model__n_estimators': 100}
- accuracy: 0.736
- precision: 0.708
- recall: 0.800
- F1: 0.751
- ROC-AUC: 0.790

Сравнение моделей по CV F1 (чем больше, тем лучше):

- RandomForest: 0.7407
- SVC: 0.7340
- GradientBoosting: 0.7318
- LogisticRegression: 0.6950

Интерпретация результатов.

Задача: классификация IC50 относительно медианы (46.59 mM).

Лучшая модель: RandomForest, F1 = 0.751, ROC-AUC = 0.790.

Классы сбалансированы (около 50/50), метрики ассурасу и F1 сопоставимы. Модель демонстрирует устойчивое качество разделения.

По дескрипторам возможно грубое разделение соединений с высокой и низкой активностью.

Наиболее значимые признаки по оценке модели: BCUT2D_MRLOW, VSA_EState8, FpDensityMorgan3. Для алгоритма они используются как числовые дескрипторы без дополнительной химической интерпретации на уровне отдельных столбцов.

4.5. Классификация: CC50 выше медианы

Численные результаты на отложенной выборке:

- порог отсечения: 411.0393423370522
- лучшая модель: LogisticRegression
- параметры: {'model__C': 0.01, 'model__penalty': 'l2'}
- accuracy: 0.716
- precision: 0.684
- recall: 0.800
- F1: 0.737
- ROC-AUC: 0.819

Сравнение моделей по CV F1 (чем больше, тем лучше):

- LogisticRegression: 0.7659
- RandomForest: 0.7659
- GradientBoosting: 0.7573
- SVC: 0.7558

Интерпретация результатов.

Порог CC50: 411.04 мМ. Лучшая модель: LogisticRegression, $F1 = 0.737$, ROC-AUC = 0.819.

В регрессии CC50 лидировал RandomForest, в классификации - LogisticRegression, что допустимо при бинарном разделении линейной границей.

Recall выше precision: модель чаще обнаруживает объекты класса 1, но допускает ложноположительные срабатывания.

Наиболее значимые признаки по оценке модели: fr_NH2, fr_sulfide, NumSaturatedHeterocycles. Для алгоритма они используются как числовые дескрипторы без дополнительной химической интерпретации на уровне отдельных столбцов.

4.6. Классификация: SI выше медианы

Численные результаты на отложенной выборке:

- порог отсечения: 3.846153846153846
- лучшая модель: RandomForest
- параметры: {'model__max_depth': 20, 'model__min_samples_leaf': 3, 'model__n_estimators': 200}
- accuracy: 0.662
- precision: 0.690
- recall: 0.580
- F1: 0.630
- ROC-AUC: 0.689

Сравнение моделей по CV F1 (чем больше, тем лучше):

- RandomForest: 0.6674
- GradientBoosting: 0.6586

- LogisticRegression: 0.6490
- SVC: 0.6463

Интерпретация результатов.

Классификация $SI > 3.85$. Модель: RandomForest, $F1 = 0.630$.

Качество ниже, чем для IC50 и CC50. SI - составной показатель, что усложняет бинарное разделение по дескрипторам.

Порог по медиане задан формально в соответствии с условиями задания.

Наиболее значимые признаки по оценке модели: VSA_EState4, BCUT2D_LOGPHI, BCUT2D_CHGLO. Для алгоритма они используются как числовые дескрипторы без дополнительной химической интерпретации на уровне отдельных столбцов.

4.7. Классификация: $SI > 8$

Численные результаты на отложенной выборке:

- порог отсечения: 8.0
- лучшая модель: RandomForest
- параметры: {'model__max_depth': 20, 'model__min_samples_leaf': 1, 'model__n_estimators': 100}
- accuracy: 0.726
- precision: 0.639
- recall: 0.542
- F1: 0.586
- ROC-AUC: 0.739

Сравнение моделей по CV F1 (чем больше, тем лучше):

- RandomForest: 0.5608

- GradientBoosting: 0.5569
- LogisticRegression: 0.5465
- SVC: 0.5279

Интерпретация результатов.

Порог $SI > 8$ (практический критерий отбора). Доля класса 1 в обучающей выборке: около 36%.

Лучшая модель: RandomForest. $F1 = 0.586$, $ROC-AUC = 0.739$. Accuracy превышает F1 из-за дисбаланса классов.

Для улучшения качества на несбалансированных данных применимы веса классов, oversampling или иные методы балансировки.

Наиболее значимые признаки по оценке модели: VSA_EState4, BCUT2D_CHGLO, BCUT2D_LOGPHI. Для алгоритма они используются как числовые дескрипторы без дополнительной химической интерпретации на уровне отдельных столбцов.

5. Сравнение подходов

Если смотреть на все семь задач целиком, картина довольно однообразная:

- Ансамбли на деревьях (RandomForest, GradientBoosting) чаще всего лидируют по метрикам качества.
- Линейные модели полезны как baseline: быстро обучаются, проще интерпретировать, но точность ниже.
- SVM занимает среднее положение. Настройка гиперпараметров чувствительная, время обучения на GridSearch ощутимое.

Регрессия SI заметно слабее регрессий IC50 и CC50. Классификация $SI > 8$ сложнее из-за дисбаланса классов.

Выбор окончательной модели для прикладных задач требует согласования с экспертами предметной области. RandomForest показал

наилучший баланс между качеством прогноза и устойчивостью на данном наборе данных.

6. Ограничения и что можно улучшить

Ограничения работы:

1. Объём выборки (1000 объектов, 190+ признаков) создаёт риск переобучения.
2. Не проводилась проверка дескрипторов на предмет утечки данных и дублирования информации.
3. Валидация выполнена на одном train/test split без внешней тестовой выборки.
4. Для задачи $SI > 8$ не применялись методы балансировки классов.
5. Нейросетевые модели и специализированные молекулярные отпечатки не использовались.

Направления дальнейшего развития:

- расширение размеченного датасета;
- экспертный отбор признаков;
- вычисление SI из прогнозов IC50 и CC50;
- настройка порогов классификации по прикладным критериям.

7. Заключение

В работе реализован полный цикл анализа табличных биохимических данных: EDA, предобработка, сравнение моделей, подбор гиперпараметров.

Выполнены все пункты задания: три задачи регрессии и четыре задачи классификации. Качество моделей умеренное: R^2 для регрессии в диапазоне 0.3-0.45, F1 для классификации 0.6-0.75 в зависимости от задачи.

Результаты демонстрируют применимость классических методов ML к задаче прогнозирования свойств соединений. Для практического использования необходима совместная интерпретация с экспертами в области медицинской химии.

Исходный код и результаты экспериментов размещены в репозитории:
https://github.com/Axer-me/classic_ml_cursovaya